

Centro Universitário Santo Agostinho
Bacharelado em Engenharia de Software 5º Período
Análise Avançada de Dados
Professor(a): Heloisa Guimarães
Dupla: José Alves e Enzo Santos

Trabalho Final – Análise Avançada de Dados

**Quais fatores mais influenciam o salário de um
profissional de dados no Brasil em 2024? Análise baseada no
State of Data Brazil 2024–2025**

1. Contexto

Nos últimos anos mercado da área dados no Brasil demonstrou um crescimento bastante acelerado, o que acaba por atrair profissionais de diferentes áreas e formações. Isso resulta c uma ampla variação salarial que nem sempre é fácil de entender. Para quem está começando na área ou planejando uma transição de carreira, a dúvida sobre o que realmente faz diferença no salário é constante.

Para responder a essa dúvida, analisamos os dados do State of Data Brazil 2024–2025, o maior mapeamento do mercado de trabalho em dados e inteligência artificial do Brasil, realizado pela comunidade Data Hackers em parceria com a Bain & Company. A pesquisa contou com 5.217 respondentes e cobre desde informações de perfil pessoal e cargo até ferramentas utilizadas e satisfação profissional.

Esta análise é direcionada a dois públicos principais: profissionais iniciantes que desejam entender quais investimentos de carreira têm maior retorno salarial, e empresas de recrutamento que buscam compreender melhor a estrutura de remuneração do setor.

2. Sobre os dados

A base utilizada é o State of Data Brazil 2024–2025, coletada entre o segundo semestre de 2024 e início de 2025, com 5.217 respondentes e mais de 400 colunas. Após o processo de limpeza, trabalhamos com 3.818 registros válidos enquanto os demais foram removidos por ausência de informações essenciais como cargo, senioridade ou faixa salarial.

Principais decisões de tratamento

A base apresentou cinco desafios principais, todos documentados e tratados antes da análise:

- Faixas salariais em texto: a coluna de salário não era numérica. Cada faixa foi convertida para seu ponto médio (ex: "de R\$4.001 a R\$6.000" foi convertido para R\$5.000). Essa decisão introduz imprecisão, especialmente na faixa superior ("Acima de R\$40.001", atribuída como R\$45.000), essa decisão é reconhecida como limitação.
- Campos de gênero e raça/cor: os valores ausentes não representam erro, mas sim que o respondente optou por não informar. Por esse motivo esses campos não foram imputados e a categoria "Não informado" foi mantida explicitamente para preservar a integridade da informação.
- Padronização de cargos: títulos como "Analista de Dados", "Data Analyst" e variações foram agrupados em categorias únicas por meio de mapeamento explícito, com critérios registrados no notebook.
- Colunas binárias de linguagem: as ferramentas utilizadas (Python, SQL, R etc.) estavam codificadas como colunas 0/1 separadas. Os 229 registros com valores ausentes nessas colunas foram imputados com 0, pois todos pertenciam aos mesmos respondentes, indicando que a questão foi pulada integralmente provavelmente porque os respondentes não utilizavam de nenhuma das tecnologias entre as opções.
- Nomes de colunas crípticos: as 12 colunas principais foram renomeadas com base no dicionário oficial antes de qualquer análise: 1.a_idade → idade, 1.a.1_faixa_idade → faixa_idade, 1.b_genero → genero, 1.c_cor/raca/etnia → raca_cor, 1.i.1_uf_onde_mora → estado, 1.l_nivel_de_ensino → nivel_ensino,

1.m_área_de_ formação → area_formacao, 2.c_numero_de_funcionarios → tamanho_empresa, 2.f_cargo_atual → cargo, 2.g_nivel → senioridade, 2.h_faixa_salarial → faixa_salarial e 2.i_tempo_de_experiencia_em_dados → tempo_experiencia_dados.

3. Achados principais

3.1 Distribuição salarial

A distribuição salarial dos profissionais de dados é assimétrica à direita: a maioria se concentra nas faixas intermediárias, enquanto uma minoria com salários muito altos eleva a média acima da mediana. Por isso, a mediana é a medida mais representativa do salário típico do setor, e é ela que utilizamos nas diferentes comparações ao longo deste relatório.

3.2 Senioridade: o fator de maior impacto

A correlação de Spearman entre senioridade e salário foi de 0,734 a mais alta entre todas as variáveis analisadas. Na prática, isso significa:

- Profissionais Júnior têm salário mediano de R\$3.500
- Profissionais Pleno têm salário mediano de R\$7.000 (2x o valor Júnior)
- Profissionais Sênior têm salário mediano de R\$14.000 (4x o valor Júnior)

Isso prova que a progressão de nível é, portanto, a alavanca mais eficiente para crescimento salarial no mercado de dados brasileiro.

3.3 Experiência: o ponto de inflexão está nos 3 a 4 anos

A correlação de Spearman entre tempo de experiência e salário foi de 0,633, indicando associação positiva moderada-forte. O achado mais relevante, porém, está na progressão por faixa:

Menos de 1 ano e sem experiência: mediana de R\$3.500

- De 1 a 2 anos: mediana de R\$5.000
- De 3 a 4 anos: mediana de R\$10.000 (o maior salto da carreira)
- A partir de 5 anos: mediana estabiliza em R\$14.000

O salário dobra entre a faixa de 1–2 anos e a de 3–4 anos. Esse é o ponto onde a mudança é mais significativa em toda a carreira em dados. O que esse dado mostra é que quem atravessa essa barreira tende a consolidar um patamar salarial significativamente mais alto. Por outro lado, observou-se que há uma estagnação após os 5 anos, o que sugere que a experiência isolada deixa de ser diferencial a partir de certo ponto e que outros fatores como cargo e especialização passam a determinar o teto salarial.

3.4 Gênero: desigualdade que persiste no topo

Em termos gerais, mulheres têm salário mediano de R\$7.000 contra R\$10.000 dos homens, uma diferença de cerca de 30%. Ao controlar pela senioridade, o cenário muda parcialmente: Entre Júniores e Plenos, a mediana é idêntica entre homens e mulheres (R\$3.500 e R\$7.000 respectivamente). Já entre Sêniors, a diferença reaparece e de maneira mais acentuada. Mulheres têm mediana de R\$10.000, homens de R\$14.000, uma diferença de 40%. Isso indica que a desigualdade salarial por gênero não é explicada apenas pela distribuição de nível de carreira. Ela é mais acentuada exatamente nos cargos mais altos, onde o impacto financeiro é maior.

3.5 Ferramentas: Python e SQL dominam

A análise das linguagens de programação utilizadas no dia a dia confirmou a dominância de Python e SQL como ferramentas essenciais no mercado. Essas duas linguagens estão presentes na grande maioria dos profissionais independentemente de cargo ou senioridade, consolidando-se como requisitos básicos de entrada na área de dados.

3. Resposta à pergunta central

Com base na análise, os fatores que mais influenciam o salário de um profissional de dados no Brasil em 2024 são, em ordem de impacto:

- Nível de senioridade (Spearman: 0,734): é o fator com maior correlação com salário. A progressão de Júnior para Sênior representa uma multiplicação de 4x na mediana salarial.
- Tempo de experiência em dados (Spearman: 0,633): fortemente associado ao salário, com o principal salto ocorrendo entre 2 e 4 anos de experiência.
- Gênero: não determina salário nos níveis iniciais, mas gera desigualdade significativa no nível Sênior, onde mulheres recebem 40% menos que homens na mediana.

O heatmap de síntese construído na Etapa 5 do notebook evidencia que senioridade e experiência atuam em conjunto, de tal maneira que, um profissional Sênior com poucos anos de experiência tende a ganhar mais do que um Júnior com mais anos de experiência, confirmando que a progressão de nível é o fator mais determinante no crescimento salarial.

5. Limitações e considerações éticas

Limitações analíticas

A conversão de faixas salariais para ponto médio introduz imprecisão, especialmente nas extremidades da distribuição. Os resultados devem ser interpretados como estimativas, não valores exatos. Outro fator muito importante é que a amostra é auto selecionada isso quer dizer que respondentes do State of Data já possuem predisposição a serem mais engajados com a comunidade de dados, o que pode superestimar o nível técnico e o salário médio do mercado como um todo. Além disso a célula Sênior com menos de 1 ano de experiência contém apenas 26 respondentes, tornando sua mediana estatisticamente instável e não confiável para interpretação. Por fim, a causalidade não pode ser estabelecida pois correlação entre experiência e salário não implica definitivamente que mais anos de experiência sozinhos causam aumento salarial. Essa afirmativa desconsidera outros fatores não medidos que podem estar envolvidos como setor de atuação da empresa (fintechs e big techs tendem a pagar mais que o mercado geral), localização geográfica (São Paulo concentra salários mais altos), nível de escolaridade e área de formação, domínio de tecnologias específicas de alta demanda, e se o profissional atua como gestor de equipe. Todos variáveis presentes na base mas não controladas neste cruzamento específico.

Considerações éticas

Os dados sobre desigualdade salarial por gênero e raça/cor exigem cuidado na comunicação. Algumas considerações importantes são que: Os campos de gênero e raça/cor têm taxa relevante de não-resposta. A ausência de dados nesses campos é em si uma informação e por esse motivo não imputamos esses valores para não distorcer a análise de grupos que optaram por não se identificar; A diferença salarial por gênero identificada nesta análise reflete um padrão estrutural do mercado de trabalho brasileiro, não uma característica isolada do setor de dados. Comunicar esse dado sem contexto pode reforçar estigmas ou ser usado de forma

distorcida; Análises sobre desigualdade racial não foram aprofundadas neste trabalho devido ao alto volume de não-respostas nesse campo, de outro modo, qualquer conclusão seria baseada em uma amostra potencialmente não representativa dos grupos mais afetados pela desigualdade. Conclui-se portanto que, esses limites não invalidam os achados, mas devem ser considerados por qualquer pessoa ou organização que utilize esta análise como base para decisões de contratação ou política salarial.

Referências

- State of Data Brazil 2024–2025. Data Hackers & Bain & Company. Disponível em: kaggle.com/datasets/datahackers/state-of-data-brazil-20242025
- Bibliotecas utilizadas: pandas, numpy, matplotlib, seaborn, scipy